

Прикладные байесовские методы

Максим Кочуров

МГУ им. М.В. Ломоносова

Лекция 1



- ① Обо мне
- ② Формальности
- ③ Мотивация
- ④ Теорема Байеса
 - Априорное распределение
 - Правдоподобие
 - Апостериорное распределение
- ⑤ Модель
- ⑥ Обсуждение
- ⑦ Дополнительные материалы
 - Программирование



- Образование:
 - бакалавриат – ЭФ МГУ (2018)
 - магистратура – Skoltech DS (2020)
- Один из разработчиков PyMC
- Ведущий дата сайентист в PyMC Labs
- Выпускник BayesGroup
- Имею опыт работы с:
 - машинным обучением и компьютерным зрением;
 - дифференциальной геометрией для графовых нейросетей;
 - байесовскими методами для глубокого обучения;
 - прикладной байесовской статистикой в индустрии (А/Б тестирование, биоинформатика).



Skoltech





Вы узнаете...

- как критически думать о вашей модели;
- какие инструменты использовать для проверки достоверности результатов;
- как презентовать ваши результаты;
- как строить непараметрические модели временных рядов.



Оценка состоит из:

- 60% домашние задания
- 40% групповой проект

Конвертация баллов в оценку

- 5 - 85%+
- 4 - 65%+
- 3 - 40%+
- 2 - < 40%



Использование LLM допускается. Бесплатный доступ к LLM:

- <https://chat.deepseek.com/>
- <https://www.kimi.com/>
- <https://qwen.ai/>
- <https://giga.chat/>

Как улучшить качество работы:

- Главное – подробно описать задачу: входные данные, требования, ожидаемый результат.
- Включить DeepThink и онлайн поиск.
- Добавить в промпт ссылку на документацию PyMC.
- Kimi умеет не только писать, но и *выполнять* код на Питоне.



- Использование в продвинутых исследованиях
 - ЦБ РФ - [байесовская модель DSGE](#) (ссылка)
 - В Google Scholar [очень много](#) (ссылка) статей, использующих PyMC
- Использование в индустрии
 - [Маркетинг в Indigo](#) (ссылка)
 - [Разработка медикаментов в Roche](#) (ссылка)
 - [Портфельная теория в Quantopian](#) (ссылка)
 - [Финансовые консультации в EverySk](#) (ссылка)
 - [Проведение опросов в Civiqs](#) (ссылка)
- Возможности карьерного роста
 - Связывают многие дисциплины и карьеры
 - Интересные предложения работы в индустрии
 - Открывают новые возможности для исследований




$$\underbrace{p(\Theta|\mathcal{D})}_{\text{BREAKING NEWS}} = \frac{\overbrace{p(\mathcal{D}|\Theta)} \overbrace{p(\Theta)}}{p(\mathcal{D})}$$

$\mathcal{D}$ = Данные

Θ = Состояние мира



$$p(\Theta|\mathcal{D}) = \frac{p(\mathcal{D}|\Theta) \overbrace{p(\Theta)}}{p(\mathcal{D})}$$



Авторы: Marielle Zondervan-Zwijnenburg, Margot Peeters, Sarah Depaoli, Rens van de Schoot [3]. Пример из байесовской эконометрики.

Исследовательский вопрос

Нужно ли усиливать контроль за потреблением подростками марихуаны?

- Долгосрочное влияние наркотиков на мозговую активность в случае употребления в раннем возрасте



Авторы: Marielle Zondervan-Zwijnenburg, Margot Peeters, Sarah Depaoli, Rens van de Schoot [3]. Пример из байесовской эконометрики.

Исследовательский вопрос

Нужно ли усиливать контроль за потреблением подростками марихуаны?

- Долгосрочное влияние наркотиков на мозговую активность в случае употребления в раннем возрасте
- Почти нет существующих исследований по теме
 - нет исследований именно о связи употребления марихуаны и мозговой активности
 - развитие сопутствующих заболеваний



Авторы: Marielle Zondervan-Zwijnenburg, Margot Peeters, Sarah Depaoli, Rens van de Schoot [3]. Пример из байесовской эконометрики.

Исследовательский вопрос

Нужно ли усиливать контроль за потреблением подростками марихуаны?

- Долгосрочное влияние наркотиков на мозговую активность в случае употребления в раннем возрасте
- Почти нет существующих исследований по теме
 - нет исследований именно о связи употребления марихуаны и мозговой активности
 - развитие сопутствующих заболеваний
- Нехватка данных



Авторы: Marielle Zondervan-Zwijnenburg, Margot Peeters, Sarah Depaoli, Rens van de Schoot [3]. Пример из байесовской эконометрики.

Исследовательский вопрос

Нужно ли усиливать контроль за потреблением подростками марихуаны?

- Долгосрочное влияние наркотиков на мозговую активность в случае употребления в раннем возрасте
- Почти нет существующих исследований по теме
 - нет исследований именно о связи употребления марихуаны и мозговой активности
 - развитие сопутствующих заболеваний
- Нехватка данных
- Классическая эконометрика не работает (16 наблюдений в группе)



Авторы: Marielle Zondervan-Zwijnenburg, Margot Peeters, Sarah Depaoli, Rens van de Schoot [3]. Пример из байесовской эконометрики.

Исследовательский вопрос

Нужно ли усиливать контроль за потреблением подростками марихуаны?

- Долгосрочное влияние наркотиков на мозговую активность в случае употребления в раннем возрасте
- Почти нет существующих исследований по теме
 - нет исследований именно о связи употребления марихуаны и мозговой активности
 - развитие сопутствующих заболеваний
- Нехватка данных
- Классическая эконометрика не работает (16 наблюдений в группе)
- Хорошо бы учесть мнение экспертов




Авторы: Marielle Zondervan-Zwijnenburg, Margot Peeters, Sarah Depaoli, Rens van de Schoot [3]. Пример из байесовской эконометрики.

Исследовательский вопрос

Нужно ли усиливать контроль за потреблением подростками марихуаны?

- Долгосрочное влияние наркотиков на мозговую активность в случае употребления в раннем возрасте
- Почти нет существующих исследований по теме
 - нет исследований именно о связи употребления марихуаны и мозговой активности
 - развитие сопутствующих заболеваний
- Нехватка данных
- Классическая эконометрика не работает (16 наблюдений в группе)
- Хорошо бы учесть мнение экспертов
- Необходимы статистические методы





Измерение объёма потребления марихуаны

- Развитие мозга можно измерить с помощью игры (Self Ordered Pointing Test [1])
- Участники проверяются на потребление марихуаны
- Подростки проходят игру 2 раза в год
- Результаты сравниваются между людьми, употребляющими марихуану **часто и редко**

Оставшиеся вопросы

- Как объём употреблённой марихуаны влияет на развитие мозга?
- Люди какого возраста менее подвержены отрицательным эффектам?
- Какой политики следует придерживаться для минимизации отрицательных эффектов?



Объединение разных источников информации для получения априорного распределения

① Знания, имевшиеся до сбора данных



② Результаты прошлых исследований:



③ Экспертное мнение

④ Ограничения



⑤ Свойства модели:



Объединение разных источников информации для получения априорного распределения

- ① Знания, имевшиеся до сбора данных
 - Практический диапазон метрики SOPT и темпов роста
- ② Результаты прошлых исследований:
- ③ Экспертное мнение
- ④ Ограничения
- ⑤ Свойства модели:





Объединение разных источников информации для получения априорного распределения

- ① Знания, имевшиеся до сбора данных
 - Практический диапазон метрики SOPT и темпов роста
- ② Результаты прошлых исследований:
 - эффект от употребления марихуаны смешан с другими заболеваниями, или о нём нет данных
 - "полезная информация была в 13 из 693 статей"
- ③ Экспертное мнение
- ④ Ограничения
- ⑤ Свойства модели:





Объединение разных источников информации для получения априорного распределения

- ① Знания, имевшиеся до сбора данных
 - Практический диапазон метрики SOPT и темпов роста
- ② Результаты прошлых исследований:
 - эффект от употребления марихуаны смешан с другими заболеваниями, или о нём нет данных
 - "полезная информация была в 13 из 693 статей"
- ③ Экспертное мнение
 - Эксперты изучили прошлые исследования
 - Связь заболеваний с употреблением марихуаны
- ④ Ограничения
- ⑤ Свойства модели:





Объединение разных источников информации для получения априорного распределения

- ① Знания, имевшиеся до сбора данных
 - Практический диапазон метрики SOPT и темпов роста
- ② Результаты прошлых исследований:
 - эффект от употребления марихуаны смешан с другими заболеваниями, или о нём нет данных
 - "полезная информация была в 13 из 693 статей"
- ③ Экспертное мнение
 - Эксперты изучили прошлые исследования
 - Связь заболеваний с употреблением марихуаны
- ④ Ограничения
 - Наклон SOPT скорее положительный, чем отрицательный
- ⑤ Свойства модели:






Объединение разных источников информации для получения априорного распределения

- ① Знания, имевшиеся до сбора данных
 - Практический диапазон метрики SOPT и темпов роста
- ② Результаты прошлых исследований:
 - эффект от употребления марихуаны смешан с другими заболеваниями, или о нём нет данных
 - "полезная информация была в 13 из 693 статей"
- ③ Экспертное мнение
 - Эксперты изучили прошлые исследования
 - Связь заболеваний с употреблением марихуаны
- ④ Ограничения
 - Наклон SOPT скорее положительный, чем отрицательный
- ⑤ Свойства модели: Знак квадратичного члена







Авторы исследования обосновали выбор априорного распределения

- ❶ Априорное распределение субъективно
- ❷ Спецификация априорного распределения непонятна
- ❸ Неверная спецификация априорного распределения



Авторы исследования обосновали выбор априорного распределения

- ❶ Априорное распределение субъективно
 - Сравнение информированного априорного распределения с неинформированным
- ❷ Спецификация априорного распределения непонятна
- ❸ Неверная спецификация априорного распределения



Авторы исследования обосновали выбор априорного распределения

- ① Априорное распределение субъективно
 - Сравнение информированного априорного распределения с неинформированным
- ② Спецификация априорного распределения непонятна
 - Принципы выбора априорного распределения описаны в разделе Logbook: <https://osf.io/aw8fy/>
- ③ Неверная спецификация априорного распределения



Авторы исследования обосновали выбор априорного распределения

- ① Априорное распределение субъективно
 - Сравнение информированного априорного распределения с неинформированным
- ② Спецификация априорного распределения непонятна
 - Принципы выбора априорного распределения описаны в разделе Logbook: <https://osf.io/aw8fy/>
- ③ Неверная спецификация априорного распределения
 - Анализ небезупречен, но это выходит за рамки лекции




$$p(\Theta|\mathcal{D}) = \frac{\overbrace{p(\mathcal{D}|\Theta)} p(\Theta)}{p(\mathcal{D})}$$



Вы продаёте орехи и хотите продать больше орехов. Как увеличить объёмы продаж?

- Увеличить вероятность покупки:
- Увеличить размер заказа





Вы продаёте орехи и хотите продать больше орехов. Как увеличить объёмы продаж?

- Увеличить вероятность покупки:
 - Баннер о здоровой еде
 - Баннер с рецептами
 - Улучшить макет сайта
- Увеличить размер заказа





Вы продаёте орехи и хотите продать больше орехов. Как увеличить объёмы продаж?

- Увеличить вероятность покупки:
 - Баннер о здоровой еде
 - Баннер с рецептами
 - Улучшить макет сайта
- Увеличить размер заказа
 - Снизить цену
 - Повысить качество
 - Улучшить упаковку





Вы продаёте орехи и хотите продать больше орехов. Как увеличить объёмы продаж?

- Увеличить вероятность покупки:
 - Баннер о здоровой еде
 - Баннер с рецептами
 - Улучшить макет сайта
- Увеличить размер заказа
 - Снизить цену
 - Повысить качество
 - Улучшить упаковку



Что лучше?

А/Б тестирование может ответить на этот вопрос

Не все потребители покупают орехи



№	Наименование	Единица измерения	Цена	Сумма
1	Орехи	кг	100	100
2	Орехи	кг	100	100
3	Орехи	кг	100	100
4	Орехи	кг	100	100
5	Орехи	кг	100	100
6	Орехи	кг	100	100
7	Орехи	кг	100	100
8	Орехи	кг	100	100
9	Орехи	кг	100	100
10	Орехи	кг	100	100

№	Наименование	Единица измерения	Цена	Сумма
1	Орехи	кг	100	100
2	Орехи	кг	100	100
3	Орехи	кг	100	100
4	Орехи	кг	100	100
5	Орехи	кг	100	100
6	Орехи	кг	100	100
7	Орехи	кг	100	100
8	Орехи	кг	100	100
9	Орехи	кг	100	100
10	Орехи	кг	100	100

№	Наименование	Единица измерения	Цена	Сумма
1	Орехи	кг	100	100
2	Орехи	кг	100	100
3	Орехи	кг	100	100
4	Орехи	кг	100	100
5	Орехи	кг	100	100
6	Орехи	кг	100	100
7	Орехи	кг	100	100
8	Орехи	кг	100	100
9	Орехи	кг	100	100
10	Орехи	кг	100	100

№	Наименование	Единица измерения	Цена	Сумма
1	Орехи	кг	100	100
2	Орехи	кг	100	100
3	Орехи	кг	100	100
4	Орехи	кг	100	100
5	Орехи	кг	100	100
6	Орехи	кг	100	100
7	Орехи	кг	100	100
8	Орехи	кг	100	100
9	Орехи	кг	100	100
10	Орехи	кг	100	100

№	Наименование	Единица измерения	Цена	Сумма
1	Орехи	кг	100	100
2	Орехи	кг	100	100
3	Орехи	кг	100	100
4	Орехи	кг	100	100
5	Орехи	кг	100	100
6	Орехи	кг	100	100
7	Орехи	кг	100	100
8	Орехи	кг	100	100
9	Орехи	кг	100	100
10	Орехи	кг	100	100

№	Наименование	Единица измерения	Цена	Сумма
1	Орехи	кг	100	100
2	Орехи	кг	100	100
3	Орехи	кг	100	100
4	Орехи	кг	100	100
5	Орехи	кг	100	100
6	Орехи	кг	100	100
7	Орехи	кг	100	100
8	Орехи	кг	100	100
9	Орехи	кг	100	100
10	Орехи	кг	100	100

№	Наименование	Единица измерения	Цена	Сумма
1	Орехи	кг	100	100
2	Орехи	кг	100	100
3	Орехи	кг	100	100
4	Орехи	кг	100	100
5	Орехи	кг	100	100
6	Орехи	кг	100	100
7	Орехи	кг	100	100
8	Орехи	кг	100	100
9	Орехи	кг	100	100
10	Орехи	кг	100	100

- Значительная часть данных – просто нули
- Классический t-тест для 2-х выборок предполагает нормальное распределение, это не наш случай
- Исследователи признают недостатки t-теста в таких случаях^[2]



- Значительная часть данных – просто нули
- Классический t-тест для 2-х выборок предполагает нормальное распределение, это не наш случай
- Исследователи признают недостатки t-теста в таких случаях[2]

Решение

Придумаем правдоподобие, не основанное на нормальном распределении



Zero Inflation (избыток нулей)

Значительная доля наблюдений в точности равна нулю



Примеры:

- Время ожидания в очереди (нет очереди – ноль)
- Дефекты на производстве (нет дефектов – ноль)
- Уровень осадков (нет осадков – ноль)
- Покупки (нет орехов – ноль)



Мудрость

В любом распределении можно повысить вероятность возникновения нулей

Пример: Zero Inflated Gamma. Параметры α, β гамма распределения и p – вероятность ненулевого наблюдения

Сэмплирование:

$$z \sim \text{Bernoulli}(p)$$
$$sample \sim \begin{cases} \text{Gamma}(\alpha, \beta), & z = 1 \\ 0, & z = 0 \end{cases}$$



Мудрость

В любом распределении можно повысить вероятность возникновения нулей

Пример: Zero Inflated Gamma. Параметры α, β гамма распределения и p – вероятность ненулевого наблюдения

Сэмплирование:

$$z \sim \text{Bernoulli}(p)$$

$$\text{sample} \sim \begin{cases} \text{Gamma}(\alpha, \beta), & z = 1 \\ 0, & z = 0 \end{cases}$$

Логарифм плотности

$$\log p(x \mid p, \alpha, \beta) = \begin{cases} \log(1 - p), & x = 0 \\ \log(p) + \frac{x^{\alpha-1} e^{-\beta x} \beta^{\alpha}}{\Gamma(\alpha)}, & x > 0 \end{cases}$$



Мудрость

В любом распределении можно повысить вероятность возникновения нулей

Пример: Zero Inflated Gamma. Параметры α, β гамма распределения и p – вероятность ненулевого наблюдения

Сэмплирование:

$$z \sim \text{Bernoulli}(p)$$

$$\text{sample} \sim \begin{cases} \text{Gamma}(\alpha, \beta), & z = 1 \\ 0, & z = 0 \end{cases}$$

Логарифм плотности

$$\log p(x \mid p, \alpha, \beta) = \begin{cases} \log(1 - p), & x = 0 \\ \log(p) + \frac{x^{\alpha-1} e^{-\beta x} \beta^{\alpha}}{\Gamma(\alpha)}, & x > 0 \end{cases}$$



Мудрость

Zero inflated распределения – разновидность смешанных распределений

Компоненты смеси:

- 1 Constant(0)
- 2 Gamma(α, β)

Параметр "смешанности" p (здесь – доля гамма распределения)

$$\text{ZI-Gamma}(p, \alpha, \beta) \equiv \text{Mixture}([1 - p, p], [\text{Constant}(0), \text{Gamma}(\alpha, \beta)])$$



заказ сделан $\sim \text{Bernoulli}(p)$

размер заказа $\sim \begin{cases} \text{Gamma}(\alpha, \beta), & \text{заказ сделан} = 1 \\ 0, & \text{заказ сделан} = 0 \end{cases}$






- Хорошее правдоподобие помогает лучше понять проблему
 - разделили вероятность покупки и размер заказа
 - больше возможностей по сравнению с классическим t -тестом
- Понимание проблемы – первый шаг к хорошему правдоподобию




$$\underbrace{p(\Theta|\mathcal{D})}_{\text{BREAKING NEWS}} = \frac{p(\mathcal{D}|\Theta)p(\Theta)}{p(\mathcal{D})}$$



$$p(\text{что вы думаете} | \text{данные}) \\ \propto p(\text{данные} | \text{что вы думаете}) p(\text{что вы думаете})$$






Media Mix Model

MMM – помогает оценивать маркетинговые каналы по историческим данным



Media Mix Models ([подробнее здесь](#))


- Насколько ценны дополнительные инвестиции в \$1000 для ВК? или Яндекс?
- Насколько велика неопределённость оценок?
- Большая ценность, но большая неопределённость, или небольшая ценность, небольшая неопределённость?
- На что выделить деньги?





Media Mix Models ([подробнее здесь](#))

- Насколько ценны дополнительные инвестиции в \$1000 для ВК? или Яндексa?
- Насколько велика неопределённость оценок?
- Большая ценность, но большая неопределённость, или небольшая ценность, небольшая неопределённость?
- На что выделить деньги?



Вывод

Оценка неопределённости помогает принять более информированные решения



Байесовский фреймворк состоит из:

- априорного распределения (что мы изначально думаем о параметрах)
- правдоподобия (имеющиеся факты)
- апостериорного распределения (представление о параметрах, обновлённое *на основе априорного распределения и данных*)




$$p_{\mathcal{M}}(\Theta|\mathcal{D}) = \frac{p_{\mathcal{M}}(\mathcal{D}|\Theta)p_{\mathcal{M}}(\Theta)}{p_{\mathcal{M}}(\mathcal{D})}$$

Модель – одно из многих описаний задачи.



Как получить хорошую модель


- 1 Начните с заведомо простой модели
- 2 Сделайте так, чтобы она хорошо сэмплировалась
- 3 Усложните модель
- 4 ...
- 5 Выберите наилучшую модель, используя кросс-валидацию





Как получить хорошую модель

- 1 Начните с заведомо простой модели
- 2 Сделайте так, чтобы она хорошо сэмплировалась
- 3 Усложните модель
- 4 ...
- 5 Выберите наилучшую модель, используя кросс-валидацию



Частая ошибка


Если начать со сложной модели, её будет сложно отлаживать



$$y(t) = \underbrace{g(t)}_{\text{тренд}} + \underbrace{s(t)}_{\text{сезонность}} + \underbrace{r(X_t)}_{\text{регрессоры}} + \varepsilon_t$$

Усложнение модели

- 1 начнём с простой модели тренда
- 2 добавим сезонность
- 3 детализируем сезонность, добавим выходные дни или другие признаки





Байесовские методы не подходят для всех случаев одновременно

- Они требуют дополнительных навыков по сравнению с классическим машинным обучением
- Вам могут не понадобиться оценки неопределённости



Байесовские методы не подходят для всех случаев одновременно

- Они требуют дополнительных навыков по сравнению с классическим машинным обучением
- Вам могут не понадобиться оценки неопределённости

Утверждение

Байесовские модели начинаются там, где заканчивается парадигма fit-predict



Байесовские методы не подходят для всех случаев одновременно

- Они требуют дополнительных навыков по сравнению с классическим машинным обучением
- Вам могут не понадобиться оценки неопределённости

Утверждение

Байесовские модели начинаются там, где заканчивается парадигма fit-predict

- Байес даёт интерпретируемые "доверительные интервалы"
- Байес даёт гибкость и контроль над моделью
- Байес надёжен при недостатке данных

Но у всего есть своя цена...

Вы **ДОЛЖНЫ** понимать свою модель

- 1 Чистый Python!
- 2 Автоматический статистический вывод
- 3 Без сложных формул для MCMC!
- 4 Визуализации с ArviZ
- 5 Воспроизводимые исследования
- 6 Используется в индустрии
- 7 Огромное сообщество
- 8 Активно разрабатывается

<https://github.com/pymc-devs/pymc>





L. Cragg and K. Nation.

Self-ordered pointing as a test of working memory in typically developing children.

Memory (Hove, England), 15:526–35, 08 2007.



F. McElduff, M. Cortina-Borja, S.-K. Chan, and A. Wade.

When t-tests or wilcoxon-mann-whitney tests won't do.

Advances in Physiology Education, 34(3):128–133, 2010.

PMID: 20826766.



M. Zondervan-Zwijnenburg, M. Peeters, S. Depaoli, and R. V. de Schoot.

Where do priors come from? applying guidelines to construct informative priors in small sample research.

Research in Human Development, 14(4):305–320, 2017.